

Abnormality classifications

Table 1. Values of QRS complex duration, RR intervals and heart rates of test and normal ECG signals

Signal	RR interval (seconds)	Heart rate (beats/min)	QRS duration (seconds)	Condition
Normal signal	0.791	75.84	0.094	STANDARD
Signal A	0.877	68.41	0.093	NORMAL
Signal B	0.911	65.83	0.088	NORMAL
Signal C	1.059	56.65	0.238	ABNORMAL
Signal D	0.80	75.00	0.080	NORMAL
Signal E	0.516	116.07	0.197	ABNORMAL
Signal F	0.78	76.90	0.083	NORMAL
Signal G	0.45	133.33	0.162	ABNORMAL

Identifying 30 ECG abnormalities from multi-source ECG databases with various lead versions. We first introduce the preliminaries of the PhysioNet/Computing in Cardiology Challenge 2021.

This dataset provided multi-source 12-lead ECG datasets and defined the metric for identification of ECG abnormalities. Challengers were expected to develop models that could accurately identify ECG abnormalities from ECG signals with various lead combinations.

Table 1. Lead combinations used in the 2021 PhysioNet/Computing in Cardiology Challenge.

Number of leads	Lead combination
12	I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6
6	I, II, III, aVR, aVL, aVF
4	I, II, III, V2
3	I, II, V2
2	I, II

1. Dataset:

In the development data, there are over 88000 ECG recordings with labeled abnormalities from eight datasets, i.e. the China Physiological Signal Challenge 2018 (CPSC and CPSC_Extra) database

2. Data Processing:

The raw data from different data sources vary in signal length, sampling frequency, signal amplitude and noise level. To remove this dataset-specific divergence that would reduce the generalizability of the classification model we adopted the preprocessing techniques detailed in the following.

2.1 Resampling, truncating and padding:

During training and testing, signals were re-sampled to a unified sample frequency (500 Hz). To address the variable length of all training ECG recordings, we randomly extracted 15s of a recording if the recording was longer than 15s, i.e. 7500 points for 500 Hz. If the length of a recording was shorter than 15s zero-padding was applied to extend the signals to 15s.

2.2 Noise reduction and amplitude normalization:

Given the importance of filtering both the high-frequency and low-frequency information reported by Nejedly et al (2021), in this work, we adopted a Butterworth bandpass filter to reduce the noise with a frequency bandwidth from 1 Hz to 47 Hz. For each lead of each ECG recording, the amplitude was normalized in the same way so that the training and testing data shared similar amplitudes. We chose Z-score normalization, as it could prevent the baseline position from deviating too much from a zero value. Then, the signals were multiplied 100 times.

3. Results:

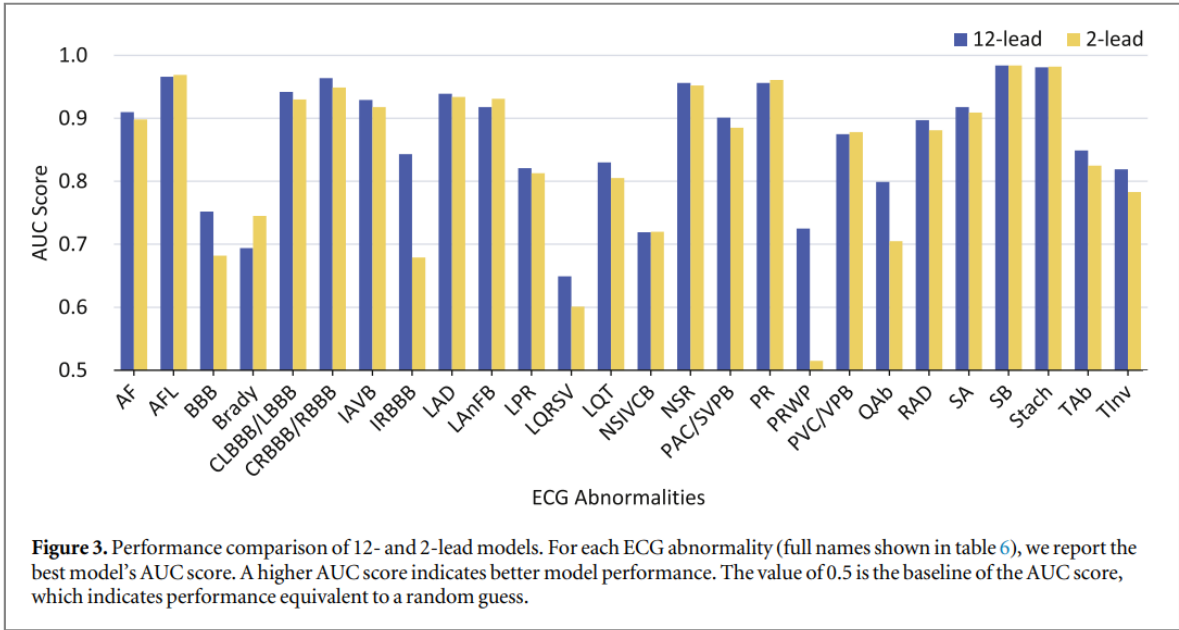


Table 6. Abbreviation of scored disease names.

Index	Disease name	Abbreviation
1	Atrial fibrillation	AF
2	Atrial flutter	AFL
3	Bundle branch block	BBB
4	Bradycardia	Brady
5	Complete left bundle branch block	CLBBB
6	Complete right bundle branch block	CRBBB
7	First degree atrioventricular block	IABV
8	Incomplete right bundle branch block	IRBBB
9	Left axis deviation	LAD
10	Left anterior fascicular block	LAnFB
11	Left bundle branch block	LBBS
12	Low QRS voltages	LQRSV
13	Nonspecific intraventricular conduction disorder	NSIVCB
14	Sinus rhythm	NSR
15	Premature atrial contraction	PAC
16	Pacing rhythm	PR
17	Poor R wave progression	PRWP
18	Premature ventricular contractions	PVC
19	Prolonged PR interval	LPR
20	Prolonged QT interval	LQT
21	Q wave abnormal	QAb
22	Right axis deviation	RAD
23	Right bundle branch block	RBBB
24	Sinus arrhythmia	SA
25	Sinus bradycardia	SB
26	Sinus tachycardia	STach
27	Supraventricular premature beats	SVPB
28	T wave abnormal	TAb
29	T wave inversion	TInv
30	Ventricular premature beats	VPB

4. Conclusions:

In this work, a deep learning framework is proposed for classification of ECG abnormalities. This study makes three main contributions. Firstly, we summarize the challenges of identifying ECG abnormalities and adopt a series of approaches to overcome them. Secondly, using the proposed framework, we train the models from multiple large datasets with sufficient labels, which can cover 30 types of ECG abnormalities and handle data with different lead combinations, while previous works focused on smaller datasets, more partial labels, fixed lead combinations and fewer abnormality types. Finally, we conduct experiments on both offline and online datasets to examine the proposed approaches, and the results on real-world datasets demonstrate the effectiveness of the proposed approaches. We believe that the models built by our proposed framework have the potential to be deployed in clinical practice.

<https://iopscience.iop.org/article/10.1088/1361-6579/ac70a4/pdf>

The classification of ECG signals using discriminating features is of crucial importance in the detection of cardiac disease and consequently in deciding path of treatment in the cardiac system. Heart rate, ST elevation, Amplitude and Duration of P wave and QRS complex are the parameters used for detection of arrhythmic activity of cardiac cycle. The coverage of larger spectrum of arrhythmia is possible with introduction of Artificial Neural Networks (ANNs). ANN classifier is implemented for the classification and an accuracy of 92.23% is achieved.

ECG waveform consists of five basic waves P, Q, R, S, and T waves and sometimes U waves. The P wave represents atrial(دهلیزی) depolarization, Q, R and S wave is commonly known as QRS complex which represents the ventricular(بطنی) depolarization and T wave represents the repolarization of ventricle. The most important part of the ECG signal analysis is the shape of QRS complex. The ECG signal may differ for the same person such that they are different from each other and at the same time similar for different types of heartbeats. The frequency range of an ECG signal is [0.05 -100] Hz and its dynamic range is [1- 10] mV. A good performance of an ECG analyzing system depends heavily upon the accurate and reliable detection of the QRS complex, as well as the T and P waves.

Feature Extraction:

Discrete Wavelet transform are used to extract features from an electrocardiogram (ECG). Better detection can be achieved by the wavelet filter with scaling function similar to the shape of the ECG signal. The wavelet is similar in shape to QRS complex and their energy spectrums are concentrated around low frequencies.

Dataset: All the ECG data required for this work is used from the MIT-BIH dataset.

The cardiac arrhythmia classification using ANN is based on:

1. Heart Rate
2. P Wave
3. QRS complex
4. ST elevations

QRS Complex

Maximum energy is stored in the component named QRS complex in ECG waveform. It provides reasonably good amount of information about the functioning capability and the pacing ability of human heart.

SR Elevation

The preceding part of ECG waveform consists of S wave and T wave and a line joining these two ends. The amplitude and time duration of both S and T wave along with ST segment provides accurate information about ventricular polarization and depolarization.

Arrhythmia classification:

Arrhythmia considered for the purpose of this study were classified into eight categories, namely

1. Left bundle branch block (LBBB)
2. Normal sinus rhythm (NSR)
3. Pre-ventricular contraction (PVC)
4. Atrial fibrillation(AF)
5. Ventricular fibrillation(VF)
6. Complete heart block (CHB)
7. Ischemic dilated Cardiomyopathy
8. Sick sinus syndrome(SSS)

Neural Network Classifier:

A method is proposed to accurately classify cardiac arrhythmias through a combination of wavelets and artificial neural network (ANN). The BPA is a supervised learning algorithm, in which a sum square error function is defined, and the learning process aims to reduce the overall system error, it is desirable that the training dataset be uniformly spread throughout the class domains. The weight updating starts with the output layer and progresses backward.




Figure-3.Single layer feed forward neural network classifier.

The ANN classifier can be a diagnostic tool to aid the physician in the analysis of heart diseases. The results show that the proposed method is effective for classification of cardiac arrhythmia with an overall accuracy of 92.23%.

Table-1.Classification of cardiac arrhythmia using ANN.

Cardiac Signal condition	data sets testing	correctly classified	sets mis-classified	% Accuracy
LBBB	24	22	2	91.67
NSR	31	30	1	96.77
PVC	65	61	4	96.77
AF	28	24	4	85.71
VF	43	39	4	90.69
CHB	29	26	3	89.66
ISCH	38	36	2	94.74
SSS	51	47	4	92.16

The non-linear parameters are used as inputs to ANN and the classification is done. The output of the classifier is a graphical representation. A few of them are shown in results.

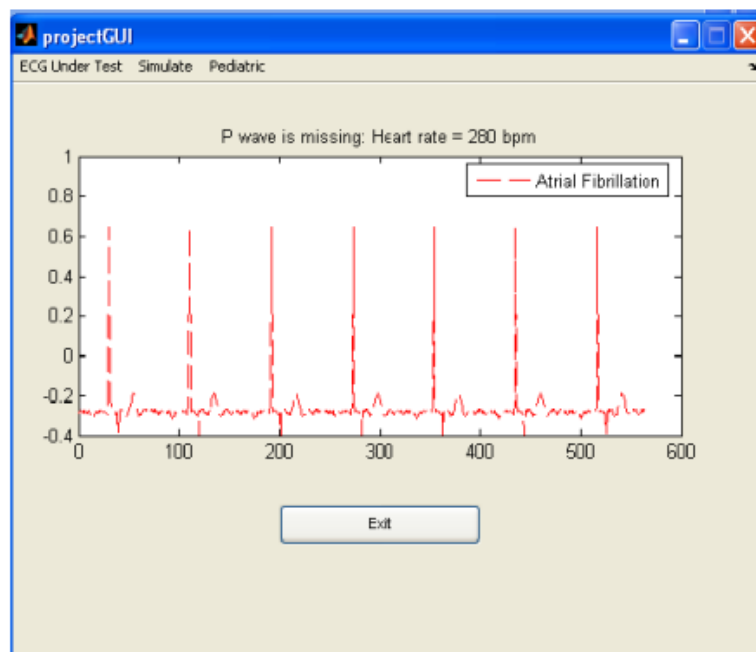


Figure-6.The output of cardiac signal-AF

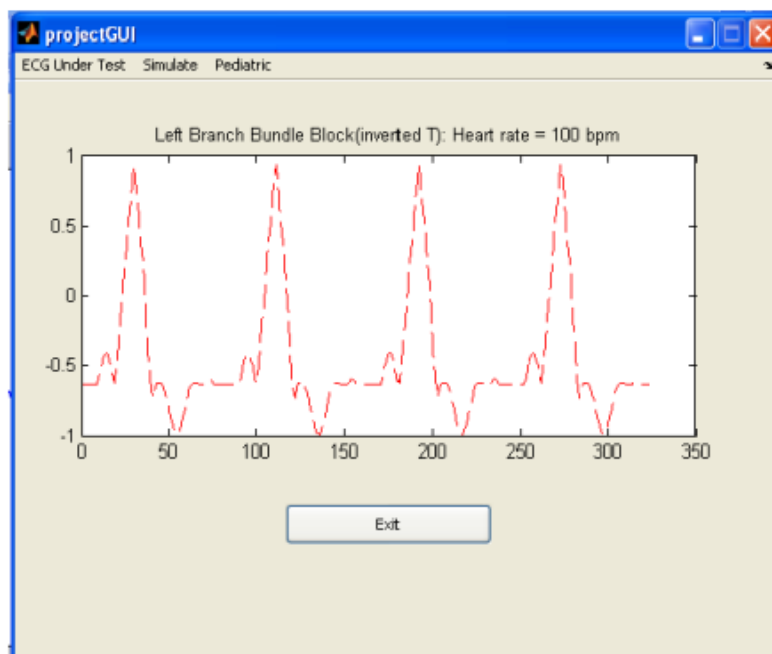


Figure-7The output of cardiac signal- LBBB.

<https://www.ijert.org/classification-of-ecg-abnormalities-using-ann>

Time	Sample #	Type	Sub	Chan	Num
0:00.050	18	+	0	0	0
0:00.214	77	N	0	0	0
0:01.028	370	N	0	0	0
0:01.839	662	N	0	0	0
0:02.628	946	N	0	0	0
0:03.419	1231	N	0	0	0
0:04.208	1515	N	0	0	0
0:05.025	1809	N	0	0	0
0:05.678	2044	A	0	0	0
0:06.672	2402	N	0	0	0
0:07.517	2706	N	0	0	0
0:08.328	2998	N	0	0	0
0:09.117	3282	N	0	0	0
0:09.889	3560	N	0	0	0
0:10.728	3862	N	0	0	0
0:11.583	4170	N	0	0	0
0:12.406	4466	N	0	0	0
0:13.233	4764	N	0	0	0
0:14.056	5060	N	0	0	0
0:14.850	5346	N	0	0	0

بیماری‌های انسداد دسته شاخه چپ (LBBB)، انقباض قبل از بطنی (PVC)، انسداد دسته شاخه راست (LBBB) و تاکی کاردی فوق بطنی (SVT) به همراه کارکرد طبیعی (Normal Beat)

در این تحقیق، پنج دسته سیگنال ذکر شده به عنوان کلاس‌های مختلف بیماری در نظر گرفته شده‌اند.

استخراج ویژگی:

داده‌ها به وسیله تبدیل‌های خطی یا غیرخطی به فضای ویژگی با ابعاد کمتر انتقال می‌یابند. مشابه پزشک نیاز است بدانیم که در چه موقعیت مکانی، چه تغییراتی (مولفه‌های فرکانسی) در سیگنال الکتروکاردیوگرافی موجود است. بنابراین، برای تفکیک و تشخیص آریتمی‌های قلبی لازم است بردار ویژگی انتخاب شده، هم ویژگی‌های زمانی و هم ویژگی‌های فرکانسی را دارا باشد.

ویژگی‌های موجک:

با توجه به اینکه ضرایب موجک قادرند اطلاعات زمان-فرکانس سیگنال را به طور توأم توصیف کنند، بهترین انتخاب برای استخراج ویژگی از یک سیگنال الکتروکاردیوگرافی خواهند بود. در این راستا باید تعداد سطوح تجزیه و نوع موجک مشخص شوند. تعداد سطوح تجزیه بر اساس مولفه فرکانسی غالب سیگنال و به گونه‌ای انتخاب می‌شود که اطلاعات بخش‌هایی از سیگنال که با فرکانس مورد نیاز برای طبقه‌بندی سیگنال به خوبی مطابقت دارند، در ضرایب موجک حفظ شوند.

در بخش پیش‌پردازش اشاره شد که سطوح اولیه تجزیه موجک (Cd1, Cd2)، اطلاعات نويز فرکانس پایین در بازه صفر تا ۵۰ هرتز را در خود دارند. نادیده گرفتن این ضرایب باعث می‌شود که اطلاعات ناچیزی از سیگنال از دست برود. همچنین، ضرایب برخی از سطوح میانی تجزیه موجک (Cd3, Cd4) نیز شامل اطلاعات همپوشانی شده‌ای هستند که باعث می‌شود سیگنال بازسازی شده با در نظر گرفتن این سطوح تجزیه میانی و نیز سطوح تجزیه اولیه، یک سیگنال هموار نباشد. با در نظر گرفتن موارد ذکر شده فوق در مرحله استخراج ویژگی، از ضرایب موجک در سه سطح ۵، ۶ و ۷ برای استخراج ویژگی استفاده شده و با استفاده از آنها ۱۵ ویژگی فهرست شده در جدول (۱) استخراج شده است.

تراز پنجم، ششم و هفتم ویژگی‌های موجک

Mean	3-1W
Var	6-4W
Max	9-7W
Median	12-10W
Sum(abs('))	15-13W

جدول (۱): ویژگی‌های موجک استخراج شده

برای توصیف کامل تر سیگنال الکتروکاردیوگرافی، علاوه بر ویژگی‌های موجک از ویژگی‌های زمانی نیز در این تحقیق استفاده شده است. ویژگی‌های زمانی مورد استفاده در این مقاله مطابق کار انجام شده در، شامل پانزده ویژگی زمانی برای تشخیص مولفه‌های شناختی از سیگنال ECG هستند که جزئیات دقیق محاسبه آن‌ها در جدول (۲) بیان شده است.

توصیف ویژگی	عنوان اختصاری
دامنه ماکزیمم سیگنال	AMP
دامنه مینیمم سیگنال	AMP-
زمان نهفتگی سیگنال	LAT
نسبت زمان نهفتگی به دامنه ماکزیمم	LAR
ناحیه مثبت	PAR
ناحیه منفی	NAR
قدر مطلق ناحیه منفی	NANR
مجموع ناحیه	TAR
قدر مطلق مجموع ناحیه	ATAR
قدر مطلق مجموع ناحیه	TAAR
پیک‌تاپیک سیگنال	PP
پنجره زمانی پیک‌تاپیک سیگنال	PPT
شیب پیک‌تاپیک سیگنال	PPS
محل عبور صفر	ZC
چگالی عبور صفر	ZCD

جدول (۲): ویژگی زمانی برای تشخیص مولفه‌های شناختی از ECG

ترکیب ویژگی‌ها و کاهش ابعاد ویژگی‌ها:

در بسیاری از موارد، برای یافتن دانش نهفته در داده‌ها، تمامی ویژگی‌های استخراج شده از روی داده‌ها مورد نیاز نیستند. به عبارتی با ادغام ویژگی‌ها و یا حذف برخی از آنها اطلاعات قابل ملاحظه‌ای از داده‌ها از بین نمی‌رود؛ ضمن اینکه زیاد بودن تعداد ویژگی‌ها باعث بالا رفتن حجم محاسبات می‌شود و در بسیاری از موارد لازم است از بین ویژگی‌های زیاد، دست به انتخاب بزنیم و یا اینکه ویژگی‌های زیاد را با هم ادغام کرده و ویژگی‌های مناسب‌تر و با ابعاد کمتر را به دست آوریم. مهمترین روش برای انتخاب و ادغام ویژگی به ترتیب استفاده از الگوریتم ژنتیک و استفاده از تحلیل مؤلفه‌های اصلی است. در این مقاله، برای کاهش ابعاد ویژگی از روش تحلیل مولفه‌های اصلی استفاده شده است.

تحلیل PCA:

در روش تحلیل مؤلفه‌های اصلی، محورهای مختصات جدیدی برای داده‌ها تعریف می‌شود به گونه‌ای که نخستین محور در جهتی قرار می‌گیرد که واریانس داده‌ها بیشینه است و دومین محور نیز عمود بر محور اول و در جهتی که واریانس داده‌ها بیشینه باشد،

در نظر گرفته می‌شود و به همین ترتیب، محورهای بعدی عمود بر تمامی محورهای قبلی به گونه‌ای قرار می‌گیرند که واریانس داده‌ها در آن جهت بیشینه باشد. برای هر یک از سیگنال‌ها، پانزده ویژگی موجک و پانزده ویژگی زمانی استخراج شده است. به این ترتیب، بردار ویژگی استخراج شده دارای ۳۰ مولفه است که با استفاده از روش تحلیل مولفه‌های اصلی به هشت مولفه کاهش پیدا می‌کند.

ساختار پیشنهادی ترکیبی برای طبقه بندی کننده ها:

ابتدا یک طبقه‌بندی کننده میانجی به عنوان مدلی از پزشک عمومی تشخیص اولیه‌ای را ارائه می‌دهد. تشخیص این طبقه‌بندی کننده میانجی در برخی از آریتمی‌ها پذیرفته شده، اما در برخی از آریتمی‌ها که تشخیص طبقه‌بندی کننده میانجی چندان قابل اطمینان نباشد، فرآیند تشخیص در قالب یک روش سلسله مراتبی به عهده یک یا چند طبقه‌بندی کننده متخصص گذاشته می‌شود. در ابتدا برای طبقه‌بندی کننده میانجی از یک شبکه عصبی استاتیکی پرسپترون (MLP) با ساختار پس‌انتشار خطا استفاده شده که به روش بهینه‌یابی Levenberg-Marquardt آموزش دیده است. این روش آموزش علی‌رغم اینکه نسبت به سایر الگوریتم‌های موجود برای آموزش شبکه عصبی به حافظه بیشتری نیاز دارد، در بیشتر موارد برای یادگیری با نظارت به‌عنوان بهترین انتخاب استفاده شود. در ادامه، ساختار دیگری مبتنی شبکه عصبی پایه شعاعی جایگزین این شبکه پرسپترون چند لایه می‌شود تا توان طبقه‌بندی را افزایش دهد.

طبقه بندی کننده MLP:

یادگیری مسائل غیرخطی مبتنی بر تصمیم‌گیری‌های متعدد با استفاده از شبکه‌های عصبی چند لایه به‌خوبی انجام می‌شود. تنظیم پارامترهای یک شبکه عصبی، از قبیل تعداد لایه‌های میانی و تعداد نرون‌های هر یک از این لایه‌ها، در رسیدن به بهترین نتیجه و جلوگیری از همگرایی غیر دقیق شبکه عصبی از اهمیت بسیاری برخوردار است.

با زیاد شدن تعداد لایه‌های میانی، شبکه قادر به درک پیچیدگی‌های بیشتری خواهد بود. از نظر ریاضی در نظر گرفتن تعداد لایه میانی بیشتر به معنی افزایش توان کدگذاری و کدبرداری بین ورودی‌ها و خروجی‌هاست. از طرف دیگر، افزایش بیش از حد لایه‌های میانی باعث پایین آمدن کارایی آموزشی شبکه می‌شود. تعداد نرون‌های لایه‌های میانی نیز به‌صورت حدسی و تجربی تعیین می‌شود. به‌طور معمول، تعداد نرون‌های لایه‌های مجاور به هم ارتباط دارد. تعداد نرون‌های لایه بعدی می‌تواند نصف و یا چند برابر تعداد نرون‌های لایه قبلی باشد.

عاملی که باید در تعیین تعداد نرون‌های لایه‌های میانی مورد توجه قرار گیرد، ایجاد تعادل بین سرعت همگرایی و قدرت تجزیه و تحلیل شبکه است. افزایش بیش از حد تعداد گره‌ها سرعت همگرایی را پایین می‌آورد. این در حالی است که کاهش بیش از حد تعداد گره‌ها باعث کم شدن توان تجزیه و تحلیل شبکه و پیرو آن کم شدن قدرت پیشگویی نهایی شبکه می‌شود. در این مقاله از یک شبکه عصبی پرسپترون با دو لایه میانی به عنوان شبکه میانجی استفاده شده است. در لایه ورودی به تعداد ویژگی‌های استخراج شده (هشت ویژگی) و در لایه خارجی به اندازه تعداد آریتمی‌ها (پنج دسته سیگنال) نرون در نظر گرفته شده است. در

لایه‌های میانی نیز به ترتیب ۱۰ و ۵۵ نرون در نظر گرفته شده است. پارامترهای شبکه عصبی پرسپترون چند لایه استفاده شده در جدول (۳) نشان داده شده است.

نوع پارامتر	مقدار پارامتر
میانگین متوسط مجذور خطا (MSE) در ده بار تکرار	01/0
تعداد تکرار	30
تعداد نرون ورودی	8
تعداد نرون‌های لایه‌های پنهان	[10,55]
تعداد نرون خروجی	5

جدول (۳): پارامترهای به کار رفته در شبکه عصبی پرسپترون چند لایه

کارایی این شبکه در طبقه‌بندی آریتمی‌های مختلف برای کل داده‌های آموزشی در جدول (۴) نشان داده شده است. مشاهده می‌شود که صحت عملکرد این طبقه‌بندی کننده ۷۶٪ است. همچنین متوسط کارایی این شبکه عصبی برای داده‌های آزمایشی در ده تکرار حدود ۴۵٪ است.

	LBBB	NOR	PVC	RBBB	SVT
LBBB	18	0	1	0	1
NOR	0	15	4	1	0
PVC	1	3	15	0	1
RBBB	0	0	1	15	4
SVT	4	0	2	1	13

جدول (۴): جدول کارایی طبقه‌بندی کننده پایه

با نگاه به جدول (۴) مشخص است که طبقه‌بندی کننده در تشخیص درست آریتمی LBBB در مقایسه با سایر آریتمی‌ها موفق‌تر بوده است (۱۸ تشخیص درست در مقابل ۵+۲ تشخیص نادرست). بنابراین در این مورد می‌توان به تشخیص طبقه‌بندی کننده میانجی اعتماد کرد. در تمایز دو به دوی چهار آریتمی باقیمانده، طبقه‌بندی کننده میانجی در تمایز بین دو آریتمی NOR و PVC بیشترین خطا را دارد (۳+۴ خطا). همچنین، خطای این طبقه‌بندی کننده در تمایز بین دو آریتمی SVT و RBBB نیز مقدار درخور توجهی است (۱+۴ خطا).

طبقه بندی کننده های ترکیبی:

با توجه به مطالب گفته شده، یک رویکرد برای طراحی ساختار ترکیبی از طبقه‌بندی کننده‌ها می‌تواند به این صورت باشد که در مورد آریتمی LBBB نظر طبقه‌بندی کننده میانجی معتبر محسوب شود، اما در مورد دو آریتمی NOR و PVC و یا SVT و

RBBB نظر طبقه‌بندی کننده‌های متخصص مربوطه معتبر محسوب شود. به این ترتیب، لازم است یک طبقه‌بندی کننده متخصص برای تمایز بین دو آریتمی NOR و PVC و طبقه‌بندی کننده متخصص دیگری برای تمایز بین دو آریتمی SVT و RBBB آموزش ببینند. در طراحی ساختارهای ترکیبی مختلف و در نظر گرفتن طبقه‌بندی کننده‌های متخصص برای رفع ابهام از تصمیم طبقه‌بندی کننده میانجی، باید به گونه‌ای عمل شود که کلاس‌های مختلف آریتمی‌های به گونه‌ای با هم ترکیب شوند که با عملیات سطری و ستونی مربوط به این کلاس ترکیبی در جدول (۴)، عناصر قطری افزایش و عناصر غیر قطری کاهش یابند. بر اساس این تحلیل، دو ساختار ترکیبی زیر برای اصلاح تصمیم طبقه‌بندی کننده میانجی طراحی شده‌اند. هر یک از طبقه‌بندی کننده‌های میانجی و متخصص روی داده‌های مربوط به خودشان آموزش داده شده‌اند. ۸۰ درصد از کل داده‌ها برای آموزش و ۲۰ درصد برای آزمایش استفاده شده‌اند. همچنین، در تکرارهای مختلف الگوریتم، داده‌های آزمایشی به صورت تصادفی از بین داده‌ها انتخاب شده‌اند.

ساختارهای ترکیبی از شبکه‌های عصبی پرسپترون چند لایه:

در این ساختارها برای طبقه‌بندی کننده میانجی و دو طبقه‌بندی کننده متخصص در هر دو ساختار الف و ب از شبکه‌های عصبی پرسپترون چند لایه استفاده شده است. جداول (۵) و (۶) به ترتیب مقادیر پارامترهای شبکه‌های عصبی مختلف در ساختار الف و ب را نشان می‌دهند.

جداول کارایی ساختارهای الف و ب برای تمامی داده‌های آموزشی به ترتیب به صورت نشان داده شده در جداول (۷) و (۸) هستند. از روی این جداول مشخص است که صحت عملکرد این ساختارها در مقایسه با طبقه‌بندی کننده میانجی (نتایج نشان داده شده در جدول (۴) بهتر شده و به ترتیب به ۸۲٪ و ۸۴٪ افزایش یافته است. متوسط کارایی این ساختارهای ترکیبی برای داده‌های آزمایشی در ده تکرار نیز در مقایسه با طبقه‌بندی کننده پایه افزایش یافته است. این مقدار برای ساختار ترکیبی الف برابر ۶۵٪ و برای ساختار ترکیبی ب برابر ۶۰٪ به دست می‌آید.

پارامترها	میانجی (MLP)	متخصص (MLP)(R-S)	متخصص (MLP)(N-P)
میانگین متوسط مجذور خطا (MSE) در ده بار تکرار	0.0088	0.0032	0.0045
تعداد تکرار	30	30	30
تعداد نرون ورودی	8	8	8
تعداد نرون پنهان	10	10	10
تعداد نرون خروجی	3	2	2

جدول (۵): پارامترهای شبکه‌های عصبی پرسپترون چندلایه در ساختار الف

پارامترها میانجی (MLP) متخصص متخصص
(MLP)(N-P-S) (MLP)(L-R)

میانگین متوسط مجذور خطا (MSE) در ده بار تکرار 0.0043
0.0002 0.0039
تعداد تکرار 30 30
تعداد نرون ورودی 8 8
تعداد نرون پنهان 10 10
تعداد نرون خروجی 2 3

جدول (۶): پارامترهای شبکه‌های عصبی پرسپترون چندلایه در ساختار ب

SVT	RBBB	PVC	NOR	LBBB	
0	0	2	0	18	LBBB
1	1	1	16	1	NOR
2	0	14	2	2	PVC
1	19	0	0	0	RBBB
15	0	0	2	3	SVT

جدول (۷): جدول کارایی مربوط به ساختار ترکیبی الف از شبکه‌های عصبی پرسپترون چند لایه

SVT	RBBB	PVC	NOR	LBBB	
2	0	1	0	17	LBBB
2	0	0	16	2	NOR
1	0	16	3	0	PVC
2	18	0	0	0	RBBB
17	0	0	0	3	SVT

جدول (۸): جدول کارایی مربوط به ساختار ترکیبی ب از شبکه‌های عصبی پرسپترون چند لایه

ساختارهای ترکیبی از شبکه‌های عصبی پرسپترون چند لایه با توابع پایه شعاعی:

لایه ورودی رابط بین داده‌های ورودی و لایه میانی است. لایه مخفی میانی یک تبدیل غیرخطی از فضای لایه ورودی انجام می‌دهد. در بیشتر کاربردها فضای لایه میانی از بعد بالایی برخوردار است. لایه خروجی نیز رفتار خطی دارد و پاسخ شبکه را فراهم می‌کند. جداول (۹) و (۱۰) به ترتیب پارامترهای ساختارهای ترکیبی الف و ب را در حالتی که برای طبقه‌بندی کننده میانجی از شبکه عصبی با توابع پایه شعاعی به جای شبکه عصبی پرسترون چند لایه استفاده شده است، نشان می‌دهد.

شبکه‌های عصبی با توابع پایه شعاعی در مقایسه با سایر شبکه‌های استاندارد پیشرو با الگوریتم پس‌انتشار خطا، تعداد نرون‌های بیشتری نیاز دارند، اما زمان مورد نیاز آنها برای آموزش در مقایسه با سایر شبکه‌های پیشروی دیگر کمتر است. جداول کارایی ساختارهای الف و ب در این حالت و برای تمامی داده‌های آموزشی به‌ترتیب به‌صورت نشان داده شده در جداول (۱۱) و (۱۲) است.

پارامترها	میانجی (RBF)	متخصص (MLP)(R-S)	متخصص (MLP)(N-P)
میانگین متوسط مجذور خطا (MSE) در ده بار تکرار	0.00043	0.0032	0.0045
تعداد تکرار	30	30	30
تعداد نرون ورودی	8	8	8
تعداد نرون پنهان	73	10	10
تعداد نرون خروجی	3	2	2

جدول (۹): پارامترهای شبکه‌های عصبی پرسپترون چندلایه (متخصص) و شبکه عصبی با توابع پایه شعاعی (میانجی) در ساختار الف

پارامترها	میانجی (RBF)	متخصص (MLP)(L-R)	متخصص (MLP)(N-P-S)
میانگین متوسط مجذور خطا (MSE) در ده بار تکرار	0.000071	0.0002	0.0039
تعداد تکرار	30	30	30
تعداد نرون ورودی	8	8	8
تعداد نرون پنهان	80	10	10
تعداد نرون خروجی	2	2	3

جدول (۱۰): پارامترهای شبکه‌های عصبی پرسپترون چندلایه (متخصص) و شبکه عصبی با توابع پایه شعاعی (میانجی) در ساختار ب

SVT	RBBB	PVC	NOR	LBBB	
0	0	0	1	19	LBBB
0	0	1	18	1	NOR
0	0	18	2	0	PVC
1	19	0	0	0	RBBB
19	1	0	0	0	SVT

جدول (۱۱): جدول کارایی مربوط به ساختار ترکیبی الف از شبکه‌های عصبی پرسپترون چند لایه و شبکه عصبی با توابع پایه شعاعی

SVT	RBBB	PVC	NOR	LBBB	
0	1	0	0	19	LBBB
2	0	0	18	0	NOR
1	0	16	0	3	PVC
0	20	0	0	0	RBBB
19	0	0	0	1	SVT

جدول (۱۲): جدول کارایی مربوط به ساختار ترکیبی ب از شبکه‌های عصبی پرسپترون چند لایه و شبکه عصبی با توابع پایه شعاعی

صحت عملکرد این ساختارها به ترتیب ۹۳٪ و ۹۲٪ است. متوسط کارایی این ساختارهای ترکیبی برای داده‌های آزمایشی در ده تکرار برای ساختار ترکیبی الف برابر ۷۰٪ و برای ساختار ترکیبی ب برابر ۸۰٪ به دست می‌آید.

نتیجه گیری:

مقایسه نتایج نشان می‌دهد که مدل سازی فرآیند تشخیص بیماری و انتقال بار تصمیم‌گیری طبقه‌بندی کننده میانجی به طبقه‌بندی کننده‌های تخصصی، در مواردی که ابهام در تصمیم‌گیری وجود دارد، صحت و دقت طبقه‌بندی را افزایش می‌دهد. این در حالی است که برای هر کدام از شبکه‌های عصبی موجود در ساختار ترکیبی پیچیدگی‌های ساختاری و آموزشی کاهش می‌یابد. همچنین بالا رفتن متوسط نرخ بازشناسی داده‌های آزمایشی در نتایج ساختار ترکیبی نشان دهنده قابلیت تعمیم بهتر این ساختار است.

در بخش قطعه‌بندی سیگنال‌های پایه انتخاب بازه‌های مناسبی برای قطعات و اعمال فیلترهای مناسبی برای کاهش نویز می‌توان دقت مرحله استخراج ویژگی را تا حد قابل ملاحظه‌ای افزایش داد.

استفاده از دیگر روش‌های ترکیب ویژگی‌ها مانند LDA و GDA می‌تواند ساختارهای ترکیبی مناسبتر دیگری را تولید و در اختیار مرحله طبقه‌بندی قرار دهد.

وجه تمایز سیستم هوشمند طراحی شده در این تحقیق نسبت به دیگر کارهای انجام شده در این زمینه، در واقع به استفاده از سیستم‌های ترکیبی شامل شبکه‌های میانجی و شبکه‌های متخصصی مربوط می‌شود که توان طبقه‌بندی بالایی را به نسبت طبقه‌بندی کننده‌های معمولی در اختیار سیستم قرار می‌دهند. از طرفی، این طبقه‌بندی کننده ترکیبی نه تنها میزان دقت تشخیص سیستم را افزایش می‌دهد؛ بلکه پیچیدگی‌های پارامتری دیگر طبقه‌بندی کننده‌ها را از جمله تعداد لایه‌های میانی سرعت همگرایی و غیره را تا حد قابل ملاحظه‌ای بهبود می‌دهد. طبقه‌بندی در این روش پیشنهادی به دقت ۹۳٪ با استفاده از سیستم‌های ترکیبی دست یافته است.

https://isee.ui.ac.ir/article_15306_00.html?lang=fa